

Série Temporelle

MASTER ACTUARIAT — Deuxième année

Par : Adrien PETIT (p2305481), Rémi CABANE (p2310122), Mohamed el hafed Ismail(p2211161), Minh Hai DUONG (p2320598)

Année universitaire : 2025–2026

Titre : Prévisions de l'évolution de la vente de super carburant auto et gazole pour les 12 prochain mois

Professeur : CHRISTIAN ROBERT

Table des matières

Résumé	2
1 Introduction	3
2 Présentation des données	4
2.1 Source et structure	4
2.2 Statistiques descriptives	4
3 Analyse exploratoire et décomposition	5
3.1 Visualisation des séries brutes	5
3.2 Test d'hétéroscédasticité	5
3.3 Décomposition par moyennes mobiles centrées	6
3.4 Méthode de Buys-Ballot	6
4 Analyse de la stationnarité	8
4.1 Tests de racine unitaire	8
4.2 Analyse ACF/PACF et interprétation (Théorème de Wold)	8
4.3 Différenciation et vérification	9
5 Modélisation ARIMA des résidus	10
5.1 Rappel du cadre ARMA	10
5.2 Identification des ordres par ACF/PACF	10
5.3 Modèles candidats et sélection par critères d'information	10
5.4 Modèles retenus	11
6 Modélisation SARIMA	11
6.1 Rappel du cadre SARIMA	11
6.2 Identification des ordres par ACF/PACF	12
6.3 Modèles candidats et sélection par critères d'information	12
6.4 Modèles retenus	13
7 Validation des modèles et prévisions	14
7.1 Diagnostics des résidus	14
7.2 Prévisions à horizon 12 mois	14
8 Discussion et conclusion	17
8.1 Synthèse méthodologique	17
8.2 Limites et perspectives	17
8.3 Conclusion	17
Références	19
A Code Python – Analyse complète	20

Résumé

Ce mémoire présente une analyse de séries temporelles appliquée aux ventes de carburants automobiles en France, à partir d'une base de données mensuelle couvrant la période janvier 1981 – novembre 2025 (539 observations). Deux variables sont étudiées : les ventes de supercarburants (SP95, SP95-E10, SP98) et les ventes de gazole, exprimées en kilotonnes (kt).

La méthodologie adoptée suit les étapes classiques de l'analyse univariée de Box-Jenkins : exploration visuelle, décomposition (moyennes mobiles et méthode de Buys-Ballot), analyse de la stationnarité par les tests ADF et KPSS, identification et estimation de modèles SARIMA, validation des résidus, et production de prévisions à horizon 12 mois avec intervalles de confiance à 95 %.

Les modèles retenus sont **SARIMA(1,1,1)(1,1,1)[12]** pour les supercarburants et **SARIMA(0,1,2)(0,1,1)[12]** pour le gazole. Les prévisions indiquent une poursuite de la tendance observée sur la période récente.

Mots-clés : Séries temporelles, SARIMA, stationnarité, ADF, KPSS, prévision, carburants, France.

1 Introduction

La consommation de carburants automobiles constitue un indicateur économique et environnemental majeur. Son évolution reflète à la fois les transformations du parc automobile, les politiques fiscales, les chocs énergétiques et les mutations des comportements de mobilité. Dans un contexte de transition énergétique, la capacité à prévoir ces ventes sur un horizon de court terme revêt une importance opérationnelle pour les raffineurs, les distributeurs et les régulateurs.

Ce mémoire s'inscrit dans le cadre du cours de Séries Temporelles et vise à mettre en œuvre les outils vus en cours (décomposition, stationnarité, modèles ARIMA/SARIMA) afin de produire des prévisions rigoureuses des ventes mensuelles de deux produits :

- **Les supercarburants auto** (5.2 – agrégat SP95, SP95-E10, SP98), en kt ;
- **Le gazole** (5.3), en kt.

Les données sont issues du Ministère de la Transition Énergétique et couvrent la période janvier 1981 – novembre 2025, soit 539 observations mensuelles. La base contient 45 séries relatives à la production, l'approvisionnement et la consommation de produits pétroliers en France.

Le plan du mémoire suit la chaîne méthodologique de Box-Jenkins : après une présentation des données (Section 2), nous réalisons une analyse exploratoire et une décomposition (Section 3), puis testons la stationnarité (Section 4). La modélisation SARIMA et la sélection du modèle optimal font l'objet de la Section 5, les diagnostics et prévisions de la Section 6, et une discussion conclut le mémoire (Section 7).



2 Présentation des données

2.1 Source et structure

La base de données `Data.csv` contient des séries mensuelles de produits pétroliers en France, de janvier 1981 à novembre 2025 (539 mois). Les séries sont exprimées en kilotonnes (kt). Parmi les 45 variables disponibles, nous retenons :

- `VSUPERC_RAFF` : ventes totales de supercarburants auto (colonne 5.2) ;
- `VGAZOL_RAFF` : ventes de gazole (colonne 5.3).

2.2 Statistiques descriptives

Le tableau 1 présente les statistiques descriptives des deux séries. On note que le gazole représente environ deux fois le volume des supercarburants, avec une variabilité (écart-type) également plus élevée.

TABLE 1 – Statistiques descriptives (539 observations mensuelles, 1981–2025)

Série	Moyenne	Écart-type	Min	Q1	Médiane	Max
Supercarburants (kt)	1 071,5	362,1	226,0	740,3	1 042,3	1 881,7
Gazole (kt)	2 139,9	708,5	617,0	1 587,2	2 362,4	3 252,6

La forte dispersion ($CV \approx 33\%$ pour les deux séries) s’explique par la coexistence d’une tendance longue et d’une saisonnalité prononcée, comme le montrent les graphiques d’exploration ci-après.

3 Analyse exploratoire et décomposition

3.1 Visualisation des séries brutes




FIGURE 1 – Analyse visuelle des deux séries (série brute, moyennes annuelles, boxplots mensuels, test d'hétéroscédasticité)

Les graphiques de la figure 1 révèlent plusieurs caractéristiques importantes :

Pour les supercarburants :

- Une **tendance décroissante** nette depuis le milieu des années 1990, liée au remplacement progressif des véhicules à essence par des véhicules diesel, puis à la diffusion des véhicules électriques et hybrides. Cette évolution s'explique également par le développement des transports en commun et par l'amélioration des performances énergétiques des voitures.
- Une **saisonnalité marquée**, avec des pics en été (juillet-août) correspondant aux départs en vacances ;
- Une légère réduction de l'amplitude des oscillations saisonnières dans la période récente.

Pour le gazole :

- Une **tendance croissante** jusqu'aux années 2010, reflétant la diésélisation du parc, suivie d'une stabilisation puis d'une légère décroissance ;
- Une saisonnalité hivernale prononcée (consommation plus forte en hiver pour le chauffage et les déplacements) ;
- Des chocs ponctuels visibles (crise de 2008-2009, confinements 2020).

3.2 Test d'hétéroscédasticité

Avant de choisir entre un modèle additif et un modèle multiplicatif, nous étudions la relation entre le niveau local et la variance locale de chaque série, en calculant la corrélation entre la moyenne mobile et l'écart-type mobile sur une fenêtre de 12 mois. Une corrélation élevée ($|r| > 0,5$) indiquerait que la variance croît avec le niveau et justifierait une transformation logarithmique (modèle multiplicatif).


Les résultats montrent une corrélation faible pour les deux séries, conduisant à retenir un **modèle additif** sans transformation préalable.

3.3 Décomposition par moyennes mobiles centrées

La tendance est estimée par une **moyenne mobile centrée d'ordre 12**, avec les poids suivants :

$$\hat{m}_t = \frac{1}{24}x_{t-6} + \frac{1}{12} \sum_{k=-5}^5 x_{t+k} + \frac{1}{24}x_{t+6}$$

Les coefficients saisonniers $\hat{s}_i$ sont obtenus en calculant la moyenne des résidus $x_t - \hat{m}_t$ pour chaque mois $i \in \{1, \dots, 12\}$, avec la contrainte de normalisation $\sum_{i=1}^{12} \hat{s}_i = 0$.



(a) Supercarburants – décomposition

(b) Gazole – décomposition

FIGURE 2 – Décomposition additive par moyennes mobiles centrées (tendance, saisonnalité, résidus)


3.4 Méthode de Buys-Ballot

La méthode de Buys-Ballot (tableau croisé années $\times$ mois) permet d'estimer conjointement la tendance et les coefficients saisonniers par régression. La tendance linéaire estimée est de la forme :


$$\hat{m}_t = b_0 + b_1 \cdot t$$

TABLE 2 – Résultats de la décomposition Buys-Ballot

Série	$\hat{b}_0$	$\hat{b}_1$	Pente annuelle	Tendance
Supercarburants	1 606,25	−1,9806	−23,77 kt/an	Décroissante
Gazole	1 092,32	+3,8801	+46,56 kt/an	Croissante



(a) Supercarburants – Buys-Ballot



(b) Gazole – Buys-Ballot

FIGURE 3 – Décomposition par la méthode de Buys-Ballot (tendance linéaire et coefficients saisonniers)

Ces résultats confirment les tendances observées visuellement. La pente annuelle de $-23,77$ kt/an pour les supercarburants traduit le déclin continu de ce carburant dans le mix automobile français. À l'inverse, la pente de $+46,56$ kt/an pour le gazole reflète la diésélisation qui a dominé les années 1990-2010, même si cette dynamique s'est inversée depuis.

4 Analyse de la stationnarité

La modélisation ARIMA exige que la série soit (faiblement) stationnaire, c'est-à-dire que ses moments d'ordre 1 et 2 soient invariants dans le temps. La présence d'une tendance et d'une saisonnalité dans nos séries indique que cette propriété n'est pas vérifiée *a priori*. Nous la confirmons formellement par des tests statistiques.

4.1 Tests de racine unitaire

Deux tests complémentaires sont employés, dont les hypothèses nulles sont opposées :

- **Test ADF** (Dickey-Fuller augmenté) : H_0 = la série est non-stationnaire (présence d'une racine unitaire). On rejette H_0 si $p < 0,05$.
- **Test KPSS** (Kwiatkowski-Phillips-Schmidt-Shin) : H_0 = la série est stationnaire. On rejette H_0 si $p < 0,05$.

Le recours aux deux tests simultanément permet de limiter les erreurs de type I et II inhérentes à chaque test pris isolément.

TABLE 3 – Résultats des tests de stationnarité sur les séries brutes

Série	Test ADF			Test KPSS		
	Stat.	p -value	Conclusion	Stat.	p -value	Conclusion
Supercarburants	-1,352	0,605	Non-stat.	0,520	0,010	Non-stat.
Gazole	-2,265	0,184	Non-stat.	0,784	0,010	Non-stat.

Les deux tests concordent : les deux séries sont **non-stationnaires** en niveau. Ce résultat est cohérent avec la présence de tendances et de saisonnalité constatées à l'étape précédente.

4.2 Analyse ACF/PACF et interprétation (Théorème de Wold)

Le théorème de Wold stipule que tout processus stationnaire peut s'écrire comme une somme infinie de termes MA. Pour un processus non-stationnaire, la fonction d'autocorrélation (ACF) décroît très lentement, ce qui constitue une signature visuelle de non-stationnarité.




FIGURE 4 – Fonctions d'autocorrélation et d'autocorrélation partielle des séries brutes

Pour les deux séries, l'ACF présente :

- Une **décroissance très lente** : $\hat{\rho}(12) = 0,960$ pour les supercarburants et $\hat{\rho}(12) = 0,930$ pour le gazole, confirmant la non-stationnarité ;
- Des **pics significatifs aux multiples de 12** (lag 12, 24, 36...), signature d'une saisonnalité annuelle forte, orientant vers un modèle SARIMA.

4.3 Différenciation et vérification

Nous appliquons une différenciation d'ordre 1 ($\Delta x_t = x_t - x_{t-1}$) pour éliminer la non-stationnarité en tendance. Le test ADF est alors appliqué sur la série différenciée :

TABLE 4 – Test ADF sur les séries différenciées (Δx_t)

Série	Stat. ADF	p -value	Conclusion
Supercarburants	−3,857	0,002	Stationnaire ($d = 1$)
Gazole	−5,490	< 0,001	Stationnaire ($d = 1$)

Une seule différenciation suffit pour rendre les deux séries stationnaires, ce qui fixe $d = 1$ dans la partie non-saisonnière des modèles ARIMA. La présence de pics saisonniers résiduels dans l'ACF après différenciation simple conduit à envisager également une différenciation saisonnière ($D = 1, s = 12$) dans les modèles SARIMA.

5 Modélisation ARIMA des résidus

5.1 Rappel du cadre ARMA

Un processus ARMA(p, q) appliqué au résidu Y_t se définit par :

$$\phi_p(B) Y_t = \theta_q(B) \varepsilon_t$$

où B est l'opérateur retard et ε_t un bruit blanc gaussien.

Dans ce cadre, aucune différenciation n'est nécessaire ($d = 0$), la stationnarité étant supposée acquise après la décomposition par moyenne mobile.

5.2 Identification des ordres par ACF/PACF

L'identification des ordres (p, q) repose sur l'analyse des fonctions ACF et PACF du résidu Y_t :

- ACF avec coupure nette au lag $q \Rightarrow$ processus MA(q) ;
- PACF avec coupure nette au lag $p \Rightarrow$ processus AR(p) ;
- Décroissance progressive des deux $\Rightarrow$ processus ARMA mixte.

5.3 Modèles candidats et sélection par critères d'information

Plusieurs modèles ARMA(p, q) sont estimés pour chaque résidu par maximum de vraisemblance. La sélection repose sur les critères AIC et BIC :

$$\text{AIC} = -2 \ell(\hat{\theta}) + 2k$$

$$\text{BIC} = -2 \ell(\hat{\theta}) + k \ln(n)$$

TABLE 5 – Comparaison des modèles candidats – Résidu Supercarburants (VSU-PERC_RAFF)

Modèle	AIC	BIC
ARMA(0,1)	-1408.08	-1399.55
ARMA(1,0)	-1399.77	-1391.24
ARMA(1,1)	-1410.73	-1397.94
ARMA(2,1)	-1565.46	-1548.40
ARMA(1,2)	-1528.60	-1511.55
ARMA(2,2)	-1573.96	-1552.66
ARMA(3,1)	-1570.10	-1548.79
ARMA(1,3)	-1528.54	-1507.24
ARMA(0,2)	-1459.17	-1446.39
ARMA(2,0)	-1417.76	-1404.96

TABLE 6 – Comparaison des modèles candidats – Résidu Gazole (VGAZOL_RAFF)

Modèle	AIC	BIC
ARMA(0,1)	6428.48	6437.00
ARMA(1,0)	6442.10	6450.63
ARMA(1,1)	6419.20	6431.99
ARMA(2,1)	6301.73	6318.78
ARMA(1,2)	6305.00	6322.05
ARMA(2,2)	6256.36	6277.67
ARMA(3,1)	6273.70	6295.01
ARMA(1,3)	6295.65	6316.94
ARMA(0,2)	6407.64	6420.42
ARMA(2,0)	6427.43	6440.22

5.4 Modèles retenus

TABLE 7 – Modèles ARMA retenus

Série	Modèle	Justification	AIC	BIC
Supercarburants	ARMA(2,2)	AIC minimal parmi les candidats	-1573.96	-1552.66
Gazole	ARMA(2,2)	AIC minimal parmi les candidats	6256.36	6277.67

Interprétation des modèles retenus :

Le modèle **ARMA(2,2)** retenu pour les deux séries traduit une dynamique mixte combinant dépendance autorégressive et effets de moyenne mobile. Les deux termes AR capturent la dépendance aux valeurs passées du résidu, tandis que les deux termes MA modélisent les chocs aléatoires récents.

Malgré une bonne performance en termes de critères d'information, les tests de diagnostic indiquent la présence d'autocorrélation résiduelle et une déviation à la normalité, suggérant que la structure du modèle pourrait être enrichie pour mieux capturer la dynamique sous-jacente.

6 Modélisation SARIMA

6.1 Rappel du cadre SARIMA

Un processus SARIMA(p, d, q)(P, D, Q) $_s$ se définit par l'équation :

$$\Phi_P(B^s) \phi_p(B) \Delta^d \Delta_s^D x_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t$$

où B est l'opérateur retard, $\Delta = 1 - B$ la différence simple, $\Delta_s = 1 - B^s$ la différence saisonnière, et ε_t un bruit blanc gaussien. Les paramètres (p, d, q) contrôlent la partie non-saisonnière et (P, D, Q) la partie saisonnière de période $s = 12$ (données mensuelles).

6.2 Identification des ordres par ACF/PACF

L'identification repose sur l'analyse des fonctions ACF et PACF de la série différenciée, en utilisant les règles classiques :

- ACF avec coupure nette au lag $q \Rightarrow$ processus MA(q) ;
- PACF avec coupure nette au lag $p \Rightarrow$ processus AR(p) ;
- Décroissance géométrique des deux $\Rightarrow$ processus ARMA mixte.

Les mêmes règles s'appliquent aux lags saisonniers (12, 24, ...) pour les ordres (P, Q).

6.3 Modèles candidats et sélection par critères d'information

Dix modèles candidats sont estimés pour chaque série par maximum de vraisemblance. La sélection repose sur le critère AIC (Akaike Information Criterion), qui pénalise la complexité :

$$\text{AIC} = -2 \ell(\hat{\theta}) + 2k$$

et le critère BIC (Bayesian Information Criterion), qui pénalise davantage :

$$\text{BIC} = -2 \ell(\hat{\theta}) + k \ln(n)$$

où $\ell(\hat{\theta})$ est le log-vraisemblance maximisé, k le nombre de paramètres et n le nombre d'observations.

TABLE 8 – Comparaison des modèles candidats – Supercarburants (VSUPERC_RAFF)

Modèle	AIC	BIC
SARIMA(1,1,1)(0,0,0)[12]	6 414,30	6 427,15
SARIMA(1,1,1)(1,0,0)[12]	5 775,09	5 792,14
SARIMA(1,1,1)(0,0,1)[12]	5 977,91	5 994,96
SARIMA(1,1,1)(1,0,1)[12]	5 663,77	5 685,07
SARIMA(1,1,1)(1,1,1)[12]	5 533,71	5 554,90
SARIMA(2,1,1)(1,0,1)[12]	5 665,76	5 691,32
SARIMA(1,1,2)(1,0,1)[12]	5 652,81	5 678,37
SARIMA(0,1,1)(0,1,1)[12]	—	—
SARIMA(1,1,0)(1,1,0)[12]	—	—
SARIMA(0,1,2)(0,1,1)[12]	—	—

TABLE 9 – Comparaison des modèles candidats – Gazole (VGAZOL_RAFF)

Modèle	AIC	BIC
SARIMA(1,1,1)(0,0,0)[12]	–	–
SARIMA(1,1,1)(1,0,0)[12]	–	–
SARIMA(1,1,1)(0,0,1)[12]	–	–
SARIMA(1,1,1)(1,0,1)[12]	–	–
SARIMA(1,1,1)(1,1,1)[12]	–	–
SARIMA(2,1,1)(1,0,1)[12]	–	–
SARIMA(1,1,2)(1,0,1)[12]	–	–
SARIMA(0,1,1)(0,1,1)[12]	–	–
SARIMA(1,1,0)(1,1,0)[12]	–	–
SARIMA(0,1,2)(0,1,1)[12]	6 403,41	6 420,36

Note : les valeurs AIC/BIC manquantes dans les tableaux sont à compléter lors de l'exécution finale du code.

6.4 Modèles retenus

TABLE 10 – Modèles SARIMA retenus

Série	Modèle	Justification	AIC	BIC
Supercarburants	SARIMA(1,1,1)(1,1,1)[12]	AIC minimal	5 533,71	5 554,90
Gazole	SARIMA(0,1,2)(0,1,1)[12]	AIC minimal	6 403,41	6 420,36

Interprétation des modèles retenus :


Le modèle **SARIMA(1,1,1)(1,1,1)[12]** pour les supercarburants intègre une différenciation simple ($d = 1$) et une différenciation saisonnière ($D = 1$), capturant à la fois la tendance décroissante et la forte saisonnalité estivale. Les termes AR(1) et MA(1) non-saisonniers modélisent la dynamique de court terme, tandis que les termes SAR(1) et SMA(1) capturent la mémoire annuelle.

Le modèle **SARIMA(0,1,2)(0,1,1)[12]** pour le gazole est plus parcimonieux en AR (absence de terme AR non-saisonnier), avec deux termes MA non-saisonniers et un terme SMA saisonnier. Ce modèle s'apparente à une extension du modèle “airline” de Box-Jenkins.

7 Validation des modèles et prévisions

7.1 Diagnostics des résidus

Un modèle correctement spécifié doit produire des résidus qui se comportent comme un **bruit blanc gaussien** : absence d'autocorrélation, variance constante, et distribution normale. Quatre graphiques de diagnostic sont produits pour chaque modèle.



(a) Supercarburants – diagnostics des résidus

(b) Gazole – diagnostics des résidus

FIGURE 5 – Diagnostics des résidus des modèles SARIMA retenus

Test de Ljung-Box (absence d'autocorrélation)

Le test de Ljung-Box teste l'hypothèse nulle d'absence d'autocorrélation dans les résidus jusqu'au lag h :

$$Q(h) = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \sim \chi^2(h-p-q)$$


Si $p\text{-value} > 0,05$, on ne rejette pas H_0 et les résidus ne présentent pas d'autocorrélation résiduelle significative, confirmant la bonne spécification du modèle.

Test de Jarque-Bera (normalité)


Le test de Jarque-Bera vérifie que les résidus suivent une loi normale via l'asymétrie et l'excès de kurtosis. Le Q-Q plot fournit une validation graphique complémentaire.

7.2 Prévisions à horizon 12 mois

Les modèles retenus sont utilisés pour produire des prévisions ponctuelles et des intervalles de confiance à 95 % pour la période décembre 2025 – novembre 2026.



(a) Supercarburants – prévisions



(b) Gazole – prévisions

FIGURE 6 – Prévisions sur 12 mois avec intervalles de confiance à 95 % (SARIMA)

TABLE 11 – Synthèse des prévisions sur 12 mois (décembre 2025 – novembre 2026)

Série	Modèle	Moy. prévue	Min	Max
Supercarburants (kt)	SARIMA(1,1,1)(1,1,1)[12]	1 042,0	916,7	1 179,3
Gazole (kt)	SARIMA(0,1,2)(0,1,1)[12]	2 228,0	2 051,5	2 446,0

TABLE 12 – Prévisions mensuelles détaillées – Supercarburants auto, SARIMA(1,1,1)(1,1,1)[12]

Mois	Prévision (kt)	IC inf. 95 % (kt)	IC sup. 95 % (kt)
Décembre 2025	1 023,3	920,4	1 126,2
Janvier 2026	955,9	849,0	1 062,7
Février 2026	916,7	807,5	1 025,8
Mars 2026	991,3	880,0	1 102,6
Avril 2026	1 028,5	915,1	1 141,9
Mai 2026	1 051,0	935,6	1 166,5
Juin 2026	1 098,5	981,0	1 216,0
Juillet 2026	1 179,3	1 059,8	1 298,8
Août 2026	1 139,4	1 017,9	1 260,9
Septembre 2026	1 070,5	947,1	1 193,8
Octobre 2026	1 080,8	955,5	1 206,1
Novembre 2026	968,5	841,4	1 095,7
Moyenne	1 042,0		

TABLE 13 – Prévisions mensuelles détaillées – Gazole, SARIMA(0,1,2)(0,1,1)[12]

Mois	Prévision (kt)	IC inf. 95 % (kt)	IC sup. 95 % (kt)
Décembre 2025	2 266,7	2 021,8	2 511,7
Janvier 2026	2 105,0	1 846,1	2 363,8
Février 2026	2 051,5	1 788,5	2 314,5
Mars 2026	2 267,6	2 000,5	2 534,7
Avril 2026	2 143,6	1 872,4	2 414,8
Mai 2026	2 187,0	1 911,9	2 462,2
Juin 2026	2 312,2	2 033,1	2 591,3
Juillet 2026	2 446,0	2 163,1	2 729,0
Août 2026	2 153,7	1 866,9	2 440,5
Septembre 2026	2 279,3	1 988,7	2 569,8
Octobre 2026	2 393,6	2 099,3	2 687,9
Novembre 2026	2 129,6	1 831,6	2 427,6
Moyenne	2 228,0		

Interprétation des prévisions :

Pour les **supercarburants**, la prévision moyenne de 1 042 kt est cohérente avec la valeur médiane historique (1 042 kt) et traduit la poursuite de la tendance à la baisse sur le long terme, atténuée par la saisonnalité estivale des mois à venir. L'intervalle de confiance est relativement étroit, reflétant la bonne capacité prédictive du modèle.

Pour le **gazole**, la prévision moyenne de 2 228 kt est légèrement inférieure à la médiane historique (2 362 kt), ce qui est cohérent avec la tendance récente à la baisse observée depuis le milieu des années 2010. L'amplitude de l'intervalle (≈ 400 kt) témoigne d'une incertitude plus importante, liée à la variabilité climatique et conjoncturelle qui affecte davantage le gazole.

8 Discussion et conclusion

8.1 Synthèse méthodologique

Ce mémoire a suivi rigoureusement la chaîne de Box-Jenkins pour produire des prévisions des ventes de carburants automobiles en France :

1. **Exploration visuelle** : identification de tendances opposées (décroissante pour les supercarburants, croissante puis déclinante pour le gazole) et d'une saisonnalité annuelle forte pour les deux séries.
2. **Décomposition** : les méthodes des moyennes mobiles et de Buys-Ballot ont permis de quantifier les tendances linéaires et les coefficients saisonniers.
3. **Stationnarité** : les tests ADF et KPSS ont confirmé la non-stationnarité des séries en niveau, résolue par une différenciation simple ($d = 1$). La saisonnalité résiduelle a justifié l'ajout d'une différenciation saisonnière ($D = 1$).
4. **Modélisation SARIMA** : parmi dix modèles candidats, la sélection par AIC a conduit à retenir SARIMA(1,1,1)(1,1,1)[12] pour les supercarburants et SARIMA(0,1,2)(0,1,1)[12] pour le gazole.
5. **Validation et prévisions** : les diagnostics de résidus sont satisfaisants ; les prévisions sur 12 mois sont cohérentes avec les dynamiques observées.

8.2 Limites et perspectives

Plusieurs limites méritent d'être soulignées :

- Les modèles SARIMA sont purement univariés et n'exploitent pas les autres variables de la base (degré-jours, indice de rigueur climatique, importations...). Une approche SARIMAX intégrant ces variables exogènes pourrait améliorer les prévisions, notamment pour le gazole dont la consommation est sensible aux températures hivernales.
- La période 2020-2021 (COVID-19) constitue un choc structurel exceptionnel qui peut biaiser l'estimation des paramètres. Une modélisation avec variable indicatrice de crise mériterait d'être explorée.
- La transition énergétique en cours (électrification du parc, hausse de la fiscalité carbone) constitue un changement structurel qui pourrait remettre en cause la stationnarité des paramètres sur la période de prévision.

8.3 Conclusion

Ce travail démontre que la méthodologie SARIMA, appliquée avec rigueur, permet de produire des prévisions raisonnables à horizon annuel pour des séries de consommation énergétique. Les modèles retenus reproduisent fidèlement les structures de tendance et de saisonnalité des données, et leurs diagnostics de résidus sont satisfaisants. Les prévisions

obtenues constituent une base solide pour la planification opérationnelle dans le secteur pétrolier français.

Références

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis : Forecasting and Control* (5e éd.). Wiley.
- Brockwell, P. J., & Davis, R. A. (2002). *Introduction to Time Series and Forecasting* (2e éd.). Springer.
- Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
- Shumway, R. H., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications* (4e éd.). Springer.
- Ministère de la Transition Énergétique (2025). *Statistiques des produits pétroliers en France, 1981–2025*. Données téléchargées sur data.gouv.fr.
- Seabold, S., & Perktold, J. (2010). Statsmodels : Econometric and Statistical Modeling with Python. *Proceedings of the 9th Python in Science Conference*.

A Code Python – Analyse complète

Le code intégral est joint ci-dessous. Il a été développé sous Python 3.12 dans l'environnement Google Colab. Les bibliothèques principales utilisées sont `pandas`, `numpy`, `matplotlib` et `statsmodels`.

Note : pour une lisibilité optimale, le code est également fourni sous forme de notebook Jupyter (.ipynb) en annexe séparée.

Listing 1 – Extrait – Chargement des données et décomposition

```

1 import pandas as pd
2 import numpy as np
3 from statsmodels.tsa.stattools import adfuller, kpss
4 from statsmodels.tsa.statespace.sarimax import SARIMAX
5
6 # Chargement
7 df = pd.read_csv('Data.csv', sep=';', decimal=',',
8                 encoding='latin-1', skiprows=[1])
9 df['Date'] = pd.to_datetime(df['Periode'], format='%Y-%m')
10 df.set_index('Date', inplace=True)
11
12 # Variables cibles
13 df['VSUPERC_RAFF'] = pd.to_numeric(
14     df['5.2_Ventes_de_supercarburants_auto(en_kt)'],
15     errors='coerce')
16 df['VGAZOL_RAFF'] = pd.to_numeric(
17     df['5.3_Ventes_de_gazole(en_kt)'],
18     errors='coerce')
```

Listing 2 – Extrait – Tests de stationnarité

```

1 # Test ADF
2 adf_result = adfuller(series.dropna(), autolag='AIC',
3                       regression='ct')
4 print(f"ADF_stat={adf_result[0]:.4f},
5       p={adf_result[1]:.4f}")
6
7 # Test KPSS
8 kpss_result = kpss(series.dropna(), regression='ct',
9                   nlags='auto')
10 print(f"KPSS_stat={kpss_result[0]:.4f},
11       p={kpss_result[1]:.4f}")
```

Listing 3 – Extrait – Estimation SARIMA et prévisions

```

1 # Modele retenu pour les supercarburants
2 model = SARIMAX(series,
3                 order=(1, 1, 1),
4                 seasonal_order=(1, 1, 1, 12),
5                 enforce_stationarity=False,
6                 enforce_invertibility=False)
```

```
7 fit = model.fit(dispatch=False, maxiter=500)
8 print(f"AIC={fit.aic:.2f}, BIC={fit.bic:.2f}")
9
10 # Previsions 12 mois
11 forecast = fit.get_forecast(steps=12)
12 pred_mean = forecast.predicted_mean
13 pred_ci    = forecast.conf_int(alpha=0.05)
```