



# Pratiques avancées de Tarification et Provisionnement

MASTER ACTUARIAT — Deuxième année

**Par :** Adrien PETIT (p2305481), Rémi CABANE (p2310122), Mohamed el hafed Ismail (p2211161)

**Année universitaire :** 2025–2026

**Titre :** Projet de tarification automobile à partir des jeux de données freMTPLfreq et freMTPLsev du paquet CASdatasets

**Professeur :** ESTERINA MASIELLO

FORMATIONS

(ACTUARIAT (ECONOMETRIE & STATISTIQUES (CONTINUE & VAE (DOCTORALE

## Table des matières

---

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction et données</b>                                     | <b>3</b>  |
| 1.1      | Description des données . . . . .                                  | 3         |
| 1.2      | Nettoyage des données . . . . .                                    | 3         |
| 1.3      | Découpage apprentissage / validation . . . . .                     | 3         |
| <b>2</b> | <b>Analyse exploratoire</b>                                        | <b>4</b>  |
| 2.1      | Indicateurs clés de sinistralité . . . . .                         | 4         |
| 2.2      | Distribution des variables explicatives . . . . .                  | 4         |
| 2.3      | Analyse des corrélations . . . . .                                 | 6         |
| 2.3.1    | Corrélation entre variables quantitatives . . . . .                | 6         |
| 2.3.2    | Association entre variables qualitatives : V de Cramer . . . . .   | 7         |
| <b>3</b> | <b>Prétraitement : regroupement de modalités et discrétisation</b> | <b>8</b>  |
| 3.1      | Justification . . . . .                                            | 8         |
| 3.2      | Regroupement de <b>Power</b> . . . . .                             | 9         |
| 3.3      | Regroupement de <b>Region</b> . . . . .                            | 10        |
| 3.4      | Regroupement de <b>Brand</b> . . . . .                             | 10        |
| 3.5      | Discrétisation des variables continues . . . . .                   | 11        |
| <b>4</b> | <b>Traitement de la sinistralité atypique (CAT)</b>                | <b>12</b> |
| 4.1      | Définition du seuil CAT . . . . .                                  | 12        |
| 4.2      | Prime CAT . . . . .                                                | 13        |
| 4.3      | Visualisation de la distribution des sinistres . . . . .           | 13        |
| <b>5</b> | <b>Modélisation de la fréquence</b>                                | <b>14</b> |
| 5.1      | Modèle de Poisson . . . . .                                        | 14        |
| 5.2      | Surdispersion et modèles alternatifs . . . . .                     | 14        |
| 5.3      | Vérification de la calibration (fréquence) . . . . .               | 15        |
| <b>6</b> | <b>Modélisation de la sévérité attritionnelle</b>                  | <b>15</b> |
| 6.1      | Modèle Gamma . . . . .                                             | 15        |
| 6.2      | Modèle Inverse Gaussien . . . . .                                  | 15        |
| 6.3      | Modèle log-normal . . . . .                                        | 15        |
| 6.4      | Comparaison des modèles . . . . .                                  | 16        |
| 6.5      | Vérification de la calibration (montants) . . . . .                | 17        |
| <b>7</b> | <b>Modélisation par XGBoost</b>                                    | <b>17</b> |
| 7.1      | Principe . . . . .                                                 | 17        |
| <b>8</b> | <b>Calcul des primes pures</b>                                     | <b>17</b> |
| 8.1      | Prime pure attritionnelle . . . . .                                | 18        |
| 8.2      | Prime pure totale . . . . .                                        | 18        |

---

|           |                                     |           |
|-----------|-------------------------------------|-----------|
| 8.3       | Comparaison GLM / XGBoost . . . . . | 18        |
| 8.4       | Distribution des primes . . . . .   | 18        |
| 8.5       | Courbes de Lorenz . . . . .         | 19        |
| <b>9</b>  | <b>Conclusions</b>                  | <b>19</b> |
| 9.1       | Bilan de la modélisation . . . . .  | 19        |
| <b>10</b> | <b>Annexes</b>                      | <b>19</b> |

## 1 Introduction et données

Ce rapport présente une démarche de tarification en assurance automobile responsabilité civile, appliquée au jeu de données **freMTPL** de la librairie R **CASdatasets**. L’objectif est de modéliser la **prime pure** individuelle, définie comme le produit de la fréquence sinistre par la sévérité, selon l’approche classique fréquence  $\times$  sévérité.

### 1.1 Description des données

Deux tables sont utilisées :

- **freMTPLfreq** : une ligne par police, contenant les caractéristiques tarifaires et le nombre de sinistres déclarés sur la période d’observation.
- **freMTPLsev** : une ligne par sinistre individuel, contenant l’identifiant de la police et le montant du sinistre.

Les variables explicatives disponibles sont les suivantes :

TABLE 1 – Variables explicatives du portefeuille

| Variable         | Type         | Description                                    |
|------------------|--------------|------------------------------------------------|
| <b>Exposure</b>  | Continue     | Durée d’exposition en fraction d’année (0 à 1) |
| <b>Power</b>     | Catégorielle | Puissance du véhicule (modalités a à o)        |
| <b>CarAge</b>    | Continue     | Âge du véhicule en années                      |
| <b>DriverAge</b> | Continue     | Âge du conducteur principal en années          |
| <b>Brand</b>     | Catégorielle | Marque du véhicule                             |
| <b>Gas</b>       | Binaire      | Type de carburant (Diesel / Regular)           |
| <b>Region</b>    | Catégorielle | Région de résidence du conducteur              |
| <b>Density</b>   | Continue     | Densité de population (hab/km <sup>2</sup> )   |

### 1.2 Nettoyage des données

Avant toute analyse, deux types d’observations aberrantes ont été retirés :

- Les polices avec **Exposure**  $> 1$  (exposition supérieure à une année, ce qui est physiquement impossible).
- Les polices avec **CarAge**  $> 98$  ans (valeurs manifestement erronées : on retrouve quand on énumère les données à la fin un nombre anormale de 98).

Après nettoyage, la base de travail conserve la quasi-totalité des polices initiales.

### 1.3 Découpage apprentissage / validation

La base nettoyée est divisée en deux échantillons :

- **Apprentissage** (80 %) : utilisé pour l’estimation de tous les modèles.
- **Validation** (20 %) : utilisé pour évaluer les performances prédictives hors-échantillon.

Le découpage est stratifié au niveau de la police afin de garantir que toutes les lignes d'une même police appartiennent au même échantillon.

## 2 Analyse exploratoire

---

### 2.1 Indicateurs clés de sinistralité

Les principaux indicateurs du portefeuille sont résumés dans le tableau suivant.

TABLE 2 – Indicateurs de sinistralité du portefeuille

| Indicateur                                 | Valeur     |
|--------------------------------------------|------------|
| Fréquence moyenne (sinistres / an-police)  | 0.0699     |
| Charge annuelle moyenne (prime pure brute) | 148.85 €   |
| Sévérité moyenne globale                   | 2130.51 €  |
| Sévérité moyenne attritionnelle            | 1470.62 €  |
| Sévérité moyenne CAT                       | 133139.8 € |
| Prime CAT mutualisée (par police)          | 26.13 €    |

### 2.2 Distribution des variables explicatives

La figure suivante présente la distribution des quatre variables continues.




FIGURE 1 – Distribution des variables continues : âge conducteur, âge véhicule, densité de population (échelle log) et exposition.

La distribution des variables catégorielles (carburant, puissance, marque, région) est présentée ci-dessous.




FIGURE 2 – Distribution des variables catégorielles.

## 2.3 Analyse des corrélations

### 2.3.1 Corrélation entre variables quantitatives

La matrice de corrélation de Pearson entre les variables continues est représentée ci-dessous.




FIGURE 3 – Matrice de corrélation de Pearson (variables quantitatives).

On observe une certaine corrélation entre les variables Exposure et DriverAge.

### 2.3.2 Association entre variables qualitatives : V de Cramer

Pour les variables catégorielles, le V de Cramer mesure la force de l'association (0 = indépendance, 1 = association parfaite). Un  $V > 0,3$  signale une redondance potentielle entre deux variables.






FIGURE 4 – V de Cramer entre les variables qualitatives tarifaires.

Les variables **Region** et **Density** présentent typiquement l'association la plus forte (la densité étant un proxy direct de l'urbanisation régionale). On observe aussi une association assez forte entre les variables **GAS** et **power** ce qui n'est pas illogique.

### 3 Prétraitement : regroupement de modalités et discrétisation

#### 3.1 Justification

L'analyse bivariée révèle que plusieurs modalités adjacentes présentent des comportements de sinistralité très proches. On procède donc à :

- Un **regroupement de modalités** pour les variables catégorielles (**Power**, **Region**, **Brand**), afin d'améliorer la crédibilité statistique des estimateurs.
- Une **discrétisation** des variables continues (**DriverAge**, **CarAge**, **Density**) en classes définies par des bornes choisies d'après les inflexions observées.

On effectue les regroupements à l'aide des graphiques ci-dessous. Un regroupement de modalités est notamment envisagé lorsque certaines d'entre elles présentent une exposition totale relativement faible. Les regroupements sont principalement réalisés selon des critères de proximité des montants observés, en particulier lorsque les charges attritionnelles sont similaires. D'autres critères plus intuitifs peuvent également être retenus, comme l'origine géographique dans le cas des marques de véhicules par exemple.

Pour la variable **Gas** il n'y a pas de regroupement à faire puisque celle-ci n'a que 2 modalités.

### 3.2 Regroupement de Power

TABLE 3 – Regroupement des modalités de Power

| Modalités initiales | Groupe retenu |
|---------------------|---------------|
| d                   | d             |
| e                   | e             |
| f                   | f             |
| g, h                | g-h           |
| i, j, k             | i-j-k         |
| l, o                | l-o           |
| m, n                | m-n           |




FIGURE 5 – Fréquence et sévérité attritionnelle par modalité de Power, avant regroupement.

### 3.3 Regroupement de Region

TABLE 4 – Regroupement des modalités de Region

| Régions initiales                                            | Groupe retenu |
|--------------------------------------------------------------|---------------|
| Aquitaine, Poitou-Charentes, Nord-Pas-de-Calais              | PC-NPDC-AQUIT |
| Pays de la Loire, Basse-Normandie, Haute-Normandie, Limousin | PDL-BN-HN-LIM |
| Île-de-France                                                | IDF           |
| Bretagne                                                     | Bretagne      |
| Centre                                                       | Centre        |




FIGURE 6 – Fréquence et sévérité attritionnelle par région, avant regroupement.

### 3.4 Regroupement de Brand

Les marques sont regroupées par origine géographique.

TABLE 5 – Regroupement des modalités de **Brand**

| Marques initiales                 | Groupe retenu |
|-----------------------------------|---------------|
| Renault, Citroën, Peugeot         | French        |
| Volkswagen, Audi, BMW, Mercedes   | Italy Germany |
| Toyota, Honda, Nissan, Mitsubishi | Asian         |
| Ford, Opel, General Motors        | US            |




FIGURE 7 – Fréquence et sévérité attritionnelle par marque, avant regroupement.

### 3.5 Discrétisation des variables continues

Les bornes de discrétisation sont choisies d'après l'analyse bivariée (inflexions observées sur la fréquence).

TABLE 6 – Bornes de discrétisation des variables continues

| Variable  | Bornes retenues                                                                |
|-----------|--------------------------------------------------------------------------------|
| DriverAge | $(-\infty, 30]$ , $(30, 45]$ , $(45, 55]$ , $(55, 65]$ , $(65, +\infty)$       |
| CarAge    | $(-\infty, 3]$ , $(3, 5]$ , $(5, 9]$ , $(9, 11]$ , $(11, +\infty)$             |
| Density   | $(0, 100]$ , $(100, 500]$ , $(500, 1000]$ , $(1000, 5000]$ , $(5000, +\infty)$ |



FIGURE 8 – Fréquence par classe pour DriverAge (pas de 5 ans), CarAge (pas de 2 ans) et Density (déciles), permettant de justifier les bornes retenues.

## 4 Traitement de la sinistralité atypique (CAT)

### 4.1 Définition du seuil CAT

On sépare la sinistralité en deux composantes :

- **Sinistres attritionnels** : montants inférieurs au quantile à 99,5 % de la distribution des sinistres individuels. Ces sinistres sont modélisés par un GLM fréquence  $\times$  sévérité.
- **Sinistres atypiques (CAT)** : montants supérieurs au seuil. Leur charge est mutualisée uniformément sur l'ensemble du portefeuille.

TABLE 7 – Séparation attritionnels / atypiques

|                     | Attritionnels | Atypiques (CAT) |
|---------------------|---------------|-----------------|
| Nombre de sinistres | 16081         | 81              |
| Part en nombre      | 99.5 %        | 0.5 %           |
| Charge totale (€)   | 23649001      | 10784326        |
| Part en charge      | 68.68 %       | 31.32 %         |

## 4.2 Prime CAT

La prime CAT est calculée par mutualisation forfaitaire :

$$\pi_{\text{CAT}} = \frac{\text{Charge CAT totale}}{\text{Nombre de polices du portefeuille}}$$

On utilise ici un modèle simplifié pour calculer la prime CAT (qui aurait pu faire l'objet de modèle de théorie des valeurs extremes) , l'idée étant plutôt de se concentrer sur le calcul de la prime pour les montant attritionnels.

## 4.3 Visualisation de la distribution des sinistres




FIGURE 9 – Distribution empirique des montants de sinistres : fonction de répartition (échelle log), densité empirique et courbe de concentration. La ligne en pointillés rouge indique le seuil CAT.

La courbe de concentration illustre la forte hétérogénéité de la sévérité : une faible proportion de sinistres concentre une part disproportionnée de la charge totale, ce qui justifie le traitement séparé des sinistres CAT.

## 5 Modélisation de la fréquence

### 5.1 Modèle de Poisson

Le modèle de base est un GLM de Poisson avec lien logarithmique et offset sur l'exposition :

$$\log(\lambda_i) = \log(E_i) + \mathbf{x}_i^\top \boldsymbol{\beta}$$

où  $\lambda_i$  est le nombre attendu de sinistres pour la police  $i$ ,  $E_i$  son exposition et  $\mathbf{x}_i$  le vecteur de ses caractéristiques.

Une sélection descendante par critère AIC (**stepAIC**) est effectuée pour ne conserver que les variables significatives.

Le modèle final retient les variables suivantes : **Power** (modalités d, i-j-k), **CarAge**, **DriverAge**, **Brand**, **Gas**, **Region** (IDF, PC-NPDC-AQUIT, PDL-BN-HN-LIM) et **Density**.

TABLE 8 – Critères d'ajustement du modèle de Poisson final (apprentissage)

| Critère             | Valeur    |
|---------------------|-----------|
| Log-vraisemblance   | -54130.48 |
| AIC                 | 108302.96 |
| BIC                 | 108527.82 |
| Déviance résiduelle | 83262.74  |

### 5.2 Surdispersion et modèles alternatifs

On teste la présence de surdispersion (variance > moyenne) par le ratio variance/moyenne pondéré par l'exposition. Si ce ratio est significativement supérieur à 1, un modèle binomial négatif est plus adapté.

TABLE 9 – Comparaison exhaustive des modèles de fréquence

| Modèle                | Log-vrais. | AIC       | BIC       | Déviance |
|-----------------------|------------|-----------|-----------|----------|
| Poisson               | -54130.48  | 108302.96 | 108527.82 | 83262.74 |
| Binomial Négatif (NB) | -53964.25  | 107972.49 | 108208.05 | 71325.27 |
| ZIP                   | -53428.90  | 106933.80 | 107340.70 | NA       |
| ZINB                  | -53428.90  | 106935.80 | 107353.40 | NA       |
| Hurdle Poisson        | -53891.50  | 107869.00 | 108329.40 | NA       |
| Hurdle NB             | -53885.42  | 107858.84 | 108329.96 | NA       |

Le modèle ZIP (Zero-Inflated Poisson) avec formules distinctes pour la partie comptage et la partie inflation de zéros est retenu comme meilleur modèle de fréquence.

### 5.3 Vérification de la calibration (fréquence)

TABLE 10 – Calibration du modèle de fréquence retenu (ZIP)

| Indicateur                 | Apprentissage | Validation |
|----------------------------|---------------|------------|
| Nombre observé (sinistres) | 12950         | 3212       |
| Nombre prédit (sinistres)  | 12961.64      | 3246.162   |

## 6 Modélisation de la sévérité attritionnelle

La modélisation de la sévérité est réalisée uniquement sur les sinistres attritionnels, après exclusion des événements atypiques (CAT). Trois modèles sont comparés : un GLM Gamma, un GLM Inverse Gaussien et un modèle log-normal.

### 6.1 Modèle Gamma

Le premier modèle considéré est un GLM Gamma avec lien logarithmique :

$$\log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\gamma}$$

où  $\mu_i = \mathbb{E}[Y_i \mid \mathbf{x}_i]$  représente le coût moyen attendu du sinistre pour l'observation  $i$ .

La distribution Gamma est classiquement utilisée en assurance pour modéliser des montants strictement positifs et asymétriques.

Une sélection pas-à-pas descendante basée sur l'AIC conduit à retenir les variables : **Power**, **CarAge**, **DriverAge**, **Brand**, **Gas** et **Region**.

### 6.2 Modèle Inverse Gaussien

Un GLM Inverse Gaussien avec lien logarithmique est également estimé :

$$\log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\delta}$$

La loi Inverse Gaussienne possède une queue plus lourde que la loi Gamma, ce qui peut améliorer la modélisation de sinistres élevés.

Comme précédemment, une sélection de variables par AIC est réalisée afin de conserver uniquement les variables significatives.

### 6.3 Modèle log-normal

Enfin, un modèle log-normal est étudié. Celui-ci consiste à modéliser le logarithme du montant du sinistre par une régression linéaire gaussienne :



$$\log(Y_i) = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Le montant du sinistre suit alors une loi log-normale conditionnellement aux variables explicatives.

La prédiction du coût moyen nécessite une correction du biais liée à l'exponentiation de la variable transformée. Ainsi, la prédiction est donnée par :

$$\widehat{Y}_i = \exp \left( \widehat{\log(Y_i)} + \frac{\widehat{\sigma}^2}{2} \right)$$

où  $\widehat{\sigma}^2$  désigne l'estimation de la variance résiduelle du modèle.

#### 6.4 Comparaison des modèles

Les différents modèles sont comparés à l'aide des critères d'information (AIC, BIC), de la log-vraisemblance et de la déviance résiduelle.

Pour le modèle lognormal, une attention particulière doit être portée au calcul de la log-vraisemblance et de l'AIC. En effet, le modèle a été estimé en supposant que le logarithme du montant des sinistres suit une loi normale, c'est-à-dire en ajustant un modèle gaussien sur  $\log(\text{ClaimAmount})$ . Les fonctions standards `logLik()` et `AIC()` de R calculent alors la vraisemblance du modèle gaussien sur les données transformées, et non celle de la loi lognormale sur les montants de sinistres initiaux. Afin d'obtenir des critères comparables avec les modèles Gamma et Inverse Gaussian, la log-vraisemblance lognormale a donc été reconstruite manuellement.

TABLE 11 – Critères des modèles de sévérité

| Modèle           | Log-vrais. | AIC      | BIC      | Déviance |
|------------------|------------|----------|----------|----------|
| Gamma            | -106802.1  | 213634.3 | 213746.3 | 12472.75 |
| Inverse Gaussien | -110075.0  | 220156.1 | 220178.5 | 26.90    |
| Log-normal       | -106850.8  | 213727.6 | NA       | NA       |

Les performances prédictives hors échantillon sont ensuite évaluées à l'aide de la RMSE (*Root Mean Squared Error*) calculée sur l'échantillon de validation.

TABLE 12 – RMSE des modèles de sévérité

| Modèle           | RMSE    |
|------------------|---------|
| Gamma            | 2325.08 |
| Inverse Gaussien | 2325.06 |
| Log-normal       | 2331.53 |

Le modèle Gamma présente le meilleur compromis entre qualité d’ajustement, stabilité et capacité prédictive. Il est donc retenu pour la modélisation finale de la sévérité attritionnelle.

## 6.5 Vérification de la calibration (montants)

TABLE 13 – Calibration du modèle de sévérité attritionnelle retenu (gamma)

| Indicateur                 | Apprentissage | Validation |
|----------------------------|---------------|------------|
| Charge totale observée (€) | 18944604      | 4704397    |
| Charge totale prédite (€)  | 18945394      | 4688078    |

## 7 Modélisation par XGBoost

### 7.1 Principe

En complément des GLM, un modèle de gradient boosting (XGBoost) est ajusté séparément sur la fréquence et la sévérité. On fait le choix de séparer comme pour les GLM le calcul de la fréquence et des montants attritionnels pour pouvoir mieux interpréter et comparer le modèle aux GLM (plutôt que d’entraîner un seul modèle : par exemple un modèle xgboost avec objectif de loi Tweedie). Les variables catégorielles sont encodées via des matrices indicatrices (one-hot encoding).

Les hyperparamètres ont été choisis manuellement (en testant manuellement plusieurs combinaisons de paramètres) mais un processus de fine tuning plus avancé pour choisir les hyperparamètres permettrait sans doute d’améliorer le modèle.

On entraîne donc 2 modèles :

- Un modèle XGBoost fréquence à objectif poisson
- Un modèle XGBoost sévérité à objectif gamma

TABLE 14 – Prédictions XGBoost sur le jeu de validation

| Indicateur                       | Valeur   |
|----------------------------------|----------|
| Nombre prédit de sinistres       | 4414.939 |
| Nombre observé de sinistres      | 3212     |
| Montant attritionnel prédit (€)  | 4663137  |
| Montant attritionnel observé (€) | 4704397  |

On observe une fréquence prédite bien trop surelevée.

## 8 Calcul des primes pures

### 8.1 Prime pure attritionnelle

La prime pure attritionnelle individuelle est définie par :

$$\hat{\pi}_i^{\text{att}} = \hat{\lambda}_i \times \hat{\mu}_i$$

où  $\hat{\lambda}_i$  est la fréquence prédite et  $\hat{\mu}_i$  la sévérité attritionnelle prédite pour la police  $i$ .

### 8.2 Prime pure totale

La prime pure totale incorpore la composante CAT mutualisée :

$$\hat{\pi}_i^{\text{total}} = \hat{\pi}_i^{\text{att}} + \pi_{\text{CAT}}$$

### 8.3 Comparaison GLM / XGBoost

TABLE 15 – Comparaison des primes pures (applique au données du jeu de test frequency)

| Modèle  | Prime moy. (€) | Prime méd. (€) | Ratio S/P (attri) | Fréquence prédite | Charge attritionnelle prédite(€) |
|---------|----------------|----------------|-------------------|-------------------|----------------------------------|
| GLM     | 83.85          | 82.83          | 1.4449            | 3246.162          | 122008931                        |
| XGBoost | 104.43         | 102.51         | 1.0656            | 4414.939          | 121022208                        |

Remarque : le modèle XGBoost a un bon S/P. Cependant celui ci semble être du à une sur-prédiction du nombre de sinistre qui contrebalance une charge attritionnelle sous-estimée. Cela ne semble donc pas être une bonne raison de le retenir.

### 8.4 Distribution des primes




FIGURE 10 – Distribution des primes pures totales (GLM vs XGBoost), limitée au percentile 99.

Les GLM proposent une distribution des primes bien plus étalée.

### 8.5 Courbes de Lorenz

Les courbes de Lorenz mesurent la capacité discriminante des modèles : une courbe plus éloignée de la diagonale indique un meilleur pouvoir de différenciation tarifaire.




FIGURE 11 – Courbes de Lorenz (proportion cumulée d'exposition vs proportion cumulée des sinistres) pour les modèles GLM et XGBoost. Les coefficients de Gini sont indiqués sur le graphique.

## 9 Conclusions

### 9.1 Bilan de la modélisation

TABLE 16 – Synthèse des choix de modélisation

| Composante              | Modèle retenu               | Justification                                   |
|-------------------------|-----------------------------|-------------------------------------------------|
| Fréquence               | ZIP (Zero-Inflated Poisson) | Meilleur AIC ; inflation de zéros significative |
| Sévérité attritionnelle | GLM Gamma                   | Distribution asymétrique positive               |
| Sinistres CAT           | Mutualisation forfaitaire   | Faible volume, forte variance                   |

Pour conclure, le modèle GLM semble plus approprié que le modèle XGBoost, notamment car il paraît plus stable. Cependant, ce modèle nécessite encore des ajustements puisque, comme l'indique le tableau précédent, il sous-estime assez fortement la charge totale (comme le montre le S/P).

## 10 Annexes